

Configuración de clientes y agentes

Qué se puede configurar hoy, dónde vive cada cosa, qué no funciona y cómo lo ordenamos para que Qora sea un producto de producción.

60

configuraciones relevadas

6

lugares distintos donde viven

17

con un problema real

En una página


Lo que encontramos

- **La configuración está repartida en 6 lugares:** base de datos, archivos del repo, dashboard de ElevenLabs, variables de Railway, código fijo y WorkOS.
- **Qora no es la fuente de verdad.** Varias cosas que se editan en el panel no llegan a la llamada real, y varias que sí importan solo se tocan a mano en ElevenLabs.
- **El sistema asume un agente por cliente** aunque la base permite varios.
- **Hay restos del prototipo de un solo cliente:** productos, nombres y valores de Quintana dentro de la plataforma.


Lo que proponemos

- **Toda la configuración del cliente y del agente en la base,** versionada.
- **Herencia con override:** estándar Qora → cliente → agente. Voz, prompt y objetivo son obligatorios por agente.
- **ElevenLabs como reflejo:** Qora aplica la config por API y detecta si alguien la tocó a mano.
- **Skills en paquetes y perfiles de análisis** por rubro.
- **No es una reescritura:** son 7 fases chicas, empezando por arreglos de 1 o 2 días.

Dónde vive cada configuración



En qué estado está



Seis fuentes para una sola llamada

Para que un agente haga una llamada, Qora junta configuración de seis lugares que no se hablan entre sí. Nadie tiene la foto completa, y un cambio en uno no se refleja en los otros.



Se pierde al deployar

Lo que se edita en el panel y vive en archivos del repo (CRM) vuelve a la versión de git en cada deploy.

Solo a mano

Primer mensaje, turnos, colgar, webhooks y voz real se cambian en el dashboard de ElevenLabs, sin rastro en Qora.

Sin pantalla

Agenda, zona horaria, idioma del análisis y reglas de próxima acción no tienen UI; dos ni siquiera API.

El viaje de la velocidad de la voz

1

Panel de Qora

El superadmin pone la velocidad en 1.0. El panel dice «se aplica en la próxima llamada».

2

Base de datos

Se guarda `tts_speed = 1.0` y el agente queda «sincronizado».

3

Sincronización

Solo envía muletilla, buzón y duración. La voz no viaja.

4

Llamada real

ElevenLabs usa su propio valor: 1.2. Similitud 1.0 en vez de 0.7.

Lo mismo pasa con el modelo de voz y con la voz elegida. Solo la demo web pisa estos valores por conexión; las llamadas telefónicas nunca.

El mismo patrón, en otros lugares

Dos agentes por cliente

La llamada entra por `/voice/quintana-seguros/custom-llm`: la URL identifica al cliente, no al agente. Qora carga siempre el agente por defecto. Un segundo agente (por ejemplo, de cobranzas) hablaría con el prompt del primero.

La memoria del lead

El análisis extrae hechos del lead (vehículo, necesidades, señales de compra) y los guarda. Ningún código los vuelve a poner en la conversación. El agente recuerda resúmenes, no el perfil.

Inventario completo

Identidad y objetivo

CONFIGURACIÓN	DÓNDE VIVE HOY	QUIÉN LA CAMBIA HOY	¿LLEGA A ELEVENLABS?	NIVEL PROPUESTO	ESTADO
Nombre del cliente	Base de datos	Superadmin (UI)	—	Cliente	Bien
Cliente activo / inactivo	Base de datos	Superadmin (UI)	—	Cliente	Bien
Slug del agente	Base de datos	Superadmin, solo al crear	—	Agente	Bien
Nombre del agente	Base de datos	Superadmin (UI)	—	Agente	Bien
Agente «por defecto»	Base de datos	Superadmin (UI)	—	Eliminar: solo agentes activos	Problema
Copia vieja de config del agente en el cliente	Base de datos	Superadmin (UI)	—	Eliminar	Sin uso
Objetivo del agente	No existe	—	—	Agente (obligatorio)	Falta

Conversación y prompt

CONFIGURACIÓN	DÓNDE VIVE HOY	QUIÉN LA CAMBIA HOY	¿LLEGA A ELEVENLABS?	NIVEL PROPUESTO	ESTADO
System prompt (archivo)	Archivo del repo	Git (deploy)	Indirecto: texto del LLM	Agente, versionado	Ordenar
System prompt (base de datos)	Base de datos	Superadmin (UI), ignorado	—	Unificar con el anterior	Problema
Prompt de cliente (prompt.md) y plantilla Jaumpablo	Código fijo	Git (deploy), respaldo viejo	—	Eliminar; queda como plantilla	Sin uso
Knowledge base (DB y knowledge.md)	Base de datos	Sin efecto; la tool de skills no la ve	—	Skill «info de la empresa»	Sin uso
Primer mensaje	Dashboard ElevenLabs	Manual (vacío hoy)	Sí, a mano	Agente	Ordenar
Idioma de la conversación	Dashboard ElevenLabs	Manual	Sí, a mano	Agente	Ordenar
Variables dinámicas por llamada	Código fijo	Fijas para autos, en 3 lugares	Sí, por llamada	Campos que define el cliente	Problema

Modelo de lenguaje

CONFIGURACIÓN	DÓNDE VIVE HOY	QUIÉN LA CAMBIA HOY	¿LLEGA A ELEVENLABS?	NIVEL PROPUESTO	ESTADO
Modelo del agente	Base de datos	Superadmin, la UI solo al crear	—	Estándar Qora + override	Ordenar
Temperatura y largo de respuesta	Base de datos	Superadmin (UI)	—	Estándar Qora + override	Bien
Modelo del análisis post-llamada (gpt-4o-mini)	Variable de entorno	Solo editando Railway	—	Estándar Qora	Ordenar
Frases de espera de las tools	Código fijo	—	—	Estándar Qora + idioma	Ordenar

Inventario completo

Voz

CONFIGURACIÓN	DÓNDE VIVE HOY	QUIÉN LA CAMBIA HOY	¿LLEGA A ELEVENLABS?	NIVEL PROPUESTO	ESTADO
Voz elegida	Dashboard ElevenLabs	Dashboard a mano; DB decorativa	Solo a mano	Agente (obligatoria)	Problema
Modelo de voz (TTS)	Base de datos	API, sin UI	No se sincroniza	Agente	Problema
Velocidad, estabilidad, similitud	Base de datos	Superadmin (UI)	Solo en la demo web	Agente	Problema
Sonido de fondo	Dashboard ElevenLabs	Manual	Sí, a mano	Agente	Ordenar
Voz y agente por defecto de plataforma	Variable de entorno	Railway	—	Eliminar	Sin uso

Turnos y control de la llamada

CONFIGURACIÓN	DÓNDE VIVE HOY	QUIÉN LA CAMBIA HOY	¿LLEGA A ELEVENLABS?	NIVEL PROPUESTO	ESTADO
Agresividad de turnos y timeout de turno	Dashboard ElevenLabs	Manual («eager» hoy)	Sí, a mano	Estándar Qora + override	Problema
Muletilla de espera (soft timeout)	Base de datos	API, sin UI	Sí, por API	Agente	Ordenar
Duración máxima de la llamada	Base de datos	API, sin UI	Sí, por API	Agente	Bien
Detección de buzón de voz	Base de datos	API, sin UI	Sí, por API	Agente	Ordenar
Colgar al terminar (end_call)	Dashboard ElevenLabs	Manual (apagado)	Sí, a mano	Agente	Problema
Palabras clave de reconocimiento	Dashboard ElevenLabs	Manual	Sí, a mano	Agente	Ordenar

Tools y skills

CONFIGURACIÓN	DÓNDE VIVE HOY	QUIÉN LA CAMBIA HOY	¿LLEGA A ELEVENLABS?	NIVEL PROPUESTO	ESTADO
Tools habilitadas	Base de datos	UI desactualizada	—	Agente	Problema
Campos de captura de datos	Archivo del repo	Superadmin (UI) → crm.yaml	—	Cliente / agente	Problema
Índice de skills (registry.yaml)	Archivo del repo	Git (deploy)	—	Paquetes de skills	Ordenar
Contenido de cada skill	Archivo del repo	Git (deploy)	—	Paquetes, versionado	Ordenar

Inventario completo

Memoria y análisis

CONFIGURACIÓN	DÓNDE VIVE HOY	QUIÉN LA CAMBIA HOY	¿LLEGA A ELEVENLABS?	NIVEL PROPUESTO	ESTADO
Cuántas llamadas previas recuerda (rotan; el 3 es fijo)	Código fijo	—	—	Estándar Qora + override	Bien
Hechos del perfil del lead	Base de datos	Se guardan, nunca se usan; calidad mixta	—	Memoria del agente, filtrados	Problema
Zona horaria de la memoria	Código fijo	Fija: Buenos Aires	—	Cliente	Ordenar
Catálogo de productos y necesidades	Código fijo	Fijo: productos de Quintana	—	Perfil de análisis	Problema
Reglas de próxima acción (qué hacer tras la llamada)	Base de datos	Nadie (sin API)	—	Perfil de análisis	Problema
Idioma de lo entregable (hereda del cliente)	Base de datos	Nadie (sin API)	—	Cliente	Problema
Configuración de extracción (columna nunca conectada)	Base de datos	Nadie: nada la lee	—	Eliminar; vive en el perfil de análisis	Sin uso

Recontacto (cliente)

CONFIGURACIÓN	DÓNDE VIVE HOY	QUIÉN LA CAMBIA HOY	¿LLEGA A ELEVENLABS?	NIVEL PROPUESTO	ESTADO
Recontacto automático (encendido / apagado)	Base de datos	API, sin UI	—	Cliente	Ordenar
Recontacto: intentos, espera y backoff	Base de datos	API, sin UI	—	Cliente	Ordenar
Horario en que se puede llamar	Base de datos	API, sin UI	—	Cliente	Ordenar
Resultados que disparan recontacto	Base de datos	API, sin validar	—	Cliente	Ordenar
Zona horaria del cliente	Base de datos	API, sin UI	—	Cliente	Ordenar
Reintento técnico y timeouts	Código fijo	—	—	Estándar Qora	Bien
Llamadas simultáneas del discador	Variable de entorno	Railway (1 global)	—	Plan del cliente	Ordenar

Inventario completo

Plan y acceso

CONFIGURACIÓN	DÓNDE VIVE HOY	QUIÉN LA CAMBIA HOY	¿LLEGA A ELEVENLABS?	NIVEL PROPUESTO	ESTADO
Plan	Base de datos	Superadmin (UI)	—	Cliente	Bien
Features y límites del plan	Base de datos	Superadmin (UI)	—	Cliente	Bien
Catálogo de planes	Código fijo	Git (deploy)	—	Estándar Qora	Bien
Organización de login	WorkOS	Superadmin (UI)	—	Cliente	Bien
Invitaciones de usuarios	WorkOS	Superadmin (UI)	—	Cliente	Bien
Superadmins	Variable de entorno	Railway	—	Qora	Bien
Límites de costo y minutos por agente	No existe	—	—	Agente	Falta

Integraciones y conexión

CONFIGURACIÓN	DÓNDE VIVE HOY	QUIÉN LA CAMBIA HOY	¿LLEGA A ELEVENLABS?	NIVEL PROPUESTO	ESTADO
CRM: base, tabla, mapeos, estados	Archivo del repo	Superadmin (UI), se pierde al deployar	—	Cliente (DB)	Problema
API key del CRM	Variable de entorno	Railway, una por cliente	—	Cliente (DB cifrada)	Problema
Número de teléfono saliente	Base de datos	API (ignorado al crear)	Sí, por llamada	Agente	Ordenar
Agente de ElevenLabs vinculado	Base de datos	Superadmin (UI)	—	Automático	Ordenar
URL del LLM, secreto y webhooks	Dashboard ElevenLabs	Copiar y pegar a mano	Sí, a mano	Automático	Problema
Trunk SIP y números	Dashboard ElevenLabs	Manual	Sí, a mano	Plataforma	Bien

Críticos: afectan llamadas reales hoy

La voz configurada en Qora no llega a las llamadas

Velocidad, estabilidad, similitud y modelo de voz solo se aplican en la demo web. En producción Qora dice 1.0 y 0.7; ElevenLabs usa 1.2 y 1.0, y Qora igual lo marca como «sincronizado».

Las llamadas siempre usan el agente por defecto del cliente

La URL del LLM es por cliente y resuelve el agente default (`webhook.py:902` , `initiation.py:110`). Con dos agentes por cliente, el segundo nunca habla con su propio prompt.

El CRM editado desde el panel se pierde en cada deploy

`crm.yaml` vive en el repo y se reescribe en el servidor. El próximo deploy lo vuelve a la versión de git. Además, la API key puede quedar escrita en ese archivo.

La API key faltante de un cliente apaga toda la plataforma

El chequeo de credenciales al arrancar corta el servidor completo si falta la key de un solo cliente. Sumar un cliente obliga a tocar Railway y reiniciar.

El análisis «universal» tiene los productos de Quintana

El catálogo de interés son los 9 seguros de Quintana (`catalog.py:20`). Cualquier cliente de otro rubro recibe un análisis de interés equivocado.

ElevenLabs no podía colgar ni detectar buzones

ElevenLabs manda sus herramientas de sistema (colgar, buzón) en cada pedido a nuestro LLM y Qora las ignoraba. Por eso Juanma decía «voy a colgar» y no colgaba. **Resuelto en la fase 0.**

Lo que el análisis aprende del lead no llega al agente

Los hechos del perfil se guardan pero nadie los inyecta en la conversación (`memory.py:147` , `_format_accumulated_profile` sin uso). La memoria real es: últimos 3 resúmenes, notas y campos del lead.

Altos y medios

Altos

Panel de tools desactualizado

3 de 4 casillas son tools que ya no existen y 5 tools reales no aparecen.

Prompt de la base ignorado sin aviso

Si existe `system-prompt.md`, editar el prompt en el panel no cambia nada. La knowledge base tampoco se usa.

Configuración sin acceso

Idioma del análisis y reglas de próxima acción no se pueden cambiar ni por API. La agenda y la zona horaria no tienen pantalla.

Agente de ElevenLabs compartido

En producción, el demo de Qora y el agente de Quintana apuntan al mismo agente de ElevenLabs.

Controles solo en el dashboard

Turnos en «eager» (interrumpe), colgar apagado, primer mensaje vacío: nada de eso se ve ni se cambia desde Qora.

Detalles de creación

El teléfono se ignora al crear un agente y el default de tools tiene nombres viejos.

Medios

Valores por defecto repetidos

Los mismos números de voz están en 3 lugares; variables de plataforma guardan nombres de Quintana.

Variables por llamada en 3 lugares

Inicio, salida y demo arman los datos del lead por separado.

Documentación desactualizada

La skill y la guía de ElevenLabs describen una sincronización vieja.

Código y settings sin uso

Pantallas duplicadas, `filler_timeout_ms`, `extraction_config`, la métrica `has_facts` (siempre falsa).

Integraciones

Un usuario cliente puede disparar el test de Airtable; las escrituras del archivo no son atómicas.

Constantes fijas

Zona horaria de la memoria, reintentos técnicos y frases de espera en español.

Una configuración, tres niveles

El valor que usa un agente sale de él mismo; si no lo define, del cliente; si tampoco, del estándar de Qora. El estándar es una guía que se puede pisar en cualquier nivel.



Dónde se guarda cada cosa

La regla: el código guarda lo de Qora, la base guarda lo de cada cliente. Dar de alta un cliente pasa a ser crear filas, no carpetas ni deploys. SQLite sigue siendo la base.




Se queda en el código

Estándares de Qora, plantillas de prompt, paquete de skills Qora, catálogo de planes, reglas técnicas de reintento. Versionado en git y revisado en PR.


Pasa a la base

Todo lo del cliente y el agente: prompt, voz, turnos, tools, skills propias, CRM, secretos cifrados, perfil de análisis. Los archivos actuales se importan una vez.

ElevenLabs como reflejo y skills en paquetes



Un agente de ElevenLabs por cada agente de Qora, creado y actualizado por la API. ElevenLabs permite agentes ilimitados en todos sus planes y cobra por **minutos** (US\$0,08 el minuto adicional) y por **llamadas simultáneas** (10 a 40 según el plan); el LLM y la telefonía van aparte. Para el pricing de Qora, lo que escala son minutos y concurrencia, no agentes. La URL del LLM pasa a identificar al agente, así cada uno usa su propio prompt.



Cada agente ve el paquete Qora, la sección general de su cliente y su propia sección. Una skill puede vivir en una sección y estar habilitada en varios agentes.

Dos paneles, permisos simples

Un cliente se configura por tres caminos: **Qora como implementador**, **un partner** (por ejemplo una agencia) o, si algún día tiene sentido, **el propio cliente**. Los tres usan el mismo panel; lo que cambia es a qué clientes tiene acceso cada uno.

Panel de configuración

Prompt, voz, skills, recontacto, CRM y análisis de un cliente. Lo usan Qora (todos los clientes), cada partner (solo sus clientes asignados) y el cliente si se autogestiona. Es la misma pantalla que hoy ve el superadmin al elegir un cliente.

Panel de operación

El día a día del cliente: llamadas, leads, resultados y monitor en vivo. Casi nada editable. Es lo que Qora fomenta: la configuración la hacemos con el cliente, a medida.

Partner = usuario con varios clientes

No hace falta un panel especial: un partner tiene una lista de clientes asignados, elige uno y entra a su panel. La sesión de login ya guarda una lista de clientes.

Estándares de Qora bloqueados

Lo que define la calidad (modelo, turnos, reglas técnicas) es configuración global de Qora: igual para todos los agentes y fuera de cualquier panel.

Todo queda registrado

Cada cambio es una revisión con autor y fecha: se puede auditar quién tocó qué y volver atrás.

Un nombre para cada cosa

Para no mezclarnos: estos son los términos que usamos de acá en adelante.

TÉRMINO	QUÉ ES
Prompt del agente	Las instrucciones de un agente. Uno solo por agente. Hoy es system-prompt.md; pasa a la base, versionado.
Plantilla de prompt	Un punto de partida de Qora para crear agentes. No se usa en llamadas.
Skill	Conocimiento que el agente carga solo cuando lo necesita (tool load_skill). La info de la empresa es una skill.
Paquete de skills	Skills de Qora o de un cliente; el cliente tiene una sección general y secciones por agente.
Variables dinámicas	Datos del lead que se insertan en cada llamada (nombre, auto...). Deben salir de los campos de cada cliente.
Memoria	Resúmenes de las últimas 3 llamadas, notas y hechos del perfil del lead.
Hechos del perfil	Datos estables de la persona que el análisis extrae (preferencias, situación).
Próxima acción	Qué hacer después de una llamada: seguir, recontactar o cerrar. La decide el análisis.
Recontacto	Cuándo y cómo se vuelve a llamar: intentos, espera, backoff, horario y resultados que lo disparan.
Perfil de análisis	La configuración del análisis post-llamada: productos, reglas de próxima acción e idioma, por rubro o cliente.
Agente de Qora / de ElevenLabs	El de Qora es la fuente de verdad; el de ElevenLabs es su reflejo, creado y actualizado por API.
Estándar de Qora	Configuración global que todos los agentes comparten y ningún panel modifica.

De acá a un producto ordenado

0

Arreglos rápidos

Sin cambiar el modelo. Que lo que se configura en Qora llegue de verdad a las llamadas.

1

Configuración del agente en la base

Prompt, voz, turnos y tools en revisiones versionadas. Los archivos pasan a ser importación inicial.

2

ElevenLabs como reflejo

Sincronizador completo, control de desvío y ruteo por agente (no por cliente).

3

Integraciones y secretos

CRM y API keys por cliente en la base, cifradas. Un cliente mal configurado no tumba a los demás.

4

Paquetes de skills

Paquete Qora + paquete del cliente con secciones por agente.

5

Perfiles de análisis

Catálogo de productos y reglas por vertical o cliente.

6

Arnés de onboarding y MCP

Dar de alta un cliente es una operación guiada; el MCP opera sobre esta misma API.

Fase 0 en detalle

- Enviar voz y parámetros de voz a ElevenLabs en la sincronización, y que «sincronizado» compare valores reales.
- Pasar turnos a una agresividad normal y habilitar «colgar» en el agente de producción.
- Corregir la lista de tools del panel y el default de la columna.
- Aceptar el teléfono al crear un agente.
- Separar el agente de ElevenLabs del demo y el de Quintana.
- Activar los hechos del perfil del lead en la memoria del agente.
- Exponer por API idioma del análisis y reglas de próxima acción.

Lo que ya definimos

Paneles

Panel de configuración (Qora, partners con sus clientes asignados, y el cliente si se autogestiona) y panel de operación para el cliente, con casi nada editable.

Estándares de Qora

Configuración global que ningún panel puede cambiar. La lista concreta se define en la fase 1.

Un agente de ElevenLabs por agente de Qora

Confirmado: ElevenLabs permite agentes ilimitados en todos los planes y cobra por minuto (US\$0,08 el adicional) y por llamadas simultáneas. La cantidad de agentes no suma costo.

Sin «agente por defecto»

Cada llamada identifica a su agente. Un cliente tiene agentes activos, no uno principal.

Idioma

Todo lo interno en inglés. Lo que lee una persona se entrega en su idioma, heredado del cliente.

Memoria

Las últimas 3 llamadas rotan (bien). Los hechos del perfil entran a la memoria, categorizados y al final del prompt, solo si la evidencia es algo que dijo la persona.

Prompt y cacheo

Lo fijo arriba, lo variable (lead, memoria, hora) al final: OpenAI cachea el inicio del prompt y cualquier dato variable corta el cache desde ese punto.

Catálogo de productos

Existe para cross-selling futuro: se mantiene, pero pasa a ser configuración de cada cliente.

Fase 0: arreglos rápidos

Hecho y verificado en producción el 2 de octubre de 2026. Cada arreglo tiene tests y su propio commit.

ARREGLO	CÓMO SE VERIFICÓ	ESTADO
La voz configurada en Qora llega a las llamadas	Juanma sincronizado: Qora lee el agente de vuelta y los valores coinciden	Resuelto
«Sincronizado» ahora es real	Si ElevenLabs no refleja lo enviado, el estado es «drift»	Resuelto
El agente puede colgar y detectar buzones	Simulación contra producción: el modelo llamó a end_call y ElevenLabs cortó	Resuelto
Turnos menos agresivos	Juanma pasó de «eager» a «normal»	Resuelto
Agente de ElevenLabs propio para el demo	Demo y Quintana ya no comparten agente	Resuelto
Login de clientes en producción	+demo entra a qora-demo; invitación enviada para Quintana	Resuelto
Panel de tools y teléfono al crear	Tests nuevos; las 5 tools reales en el panel	Resuelto
Idioma y reglas de próxima acción por API	Editables por API; validados en producción	Resuelto
Hechos del perfil en la memoria	8 hechos en el contexto de tu lead; los nuevos se filtran	Resuelto
Limpiar hechos viejos mal extraídos	Pendiente: el filtro no corrige los ya guardados	Pendiente